UNIVERSIDADE ESTADUAL DE CAMPINAS - UNICAMP
INSTITUTO DE MATEMÁTICA, ESTATÍSTICA E COMPUTAÇÃO CIENTÍFICA

Relatório MS903

Professor
Stefano De Leo

Alunos
Alex Lei 288915
Davi Soares Magalhães 295860
Erik Ventorini 206186
Felipe de Freitas Percinoto 275170

2026

Abstract

Neste relatório estaremos desenvolvendo e comentando sobre o conteúdo visto em aula referente aos tópicos da curva Gaussiana, lançamento de dados, RR, OR, HR, Regressão Linear e analisando como essas ferramentas são desenvolvidas e a aplicação de algumas delas no contexto da pandemia no Brasil.

Sumário

1 Tópico 1: Introdução à distribuição Gaussiana **2**
1.1 Lançamento de dados e funções geradoras 2
1.1.1 Funções Geradoras 2
1.1.2 Probabilidade de um resultado com funções geradoras 2
1.1.3 Resultados com outros tipos de dados 2
1.2 A distribuição Gaussiana 3

2 Tópico 2: Relative Risk, Odds Ratio e Hazard Ratio **4**
2.1 Relative Risk (RR) 4
2.2 Odds Ratio (OR) 4
2.3 Hazard Ratio (HR) 5

3 Tópico 3: Introdução a Regressão Linear **5**
3.1 O Modelo Estocástico e Hipóteses 5
3.2 Definições Prévias 5
3.3 Estimadores de Mínimos Quadrados 6
3.4 Exemplo Dado em Sala de Aula 6
3.4.1 Conjunto de Dados e Amostragem 6
3.4.2 Ajuste do Modelo e Análise de Convergência 7
3.4.3 Interpretação Física e Gráfica 7

4 Análise de Variância e Resíduos **7**
4.1 Qualidade de Ajuste (R^2) 7
4.2 Inferência Estatística 7
4.2.1 Erros Padrão e Teste de Hipótese 7
4.2.2 Intervalos de Confiança para Parâmetros 8
4.2.3 Intervalos de Previsão e Resposta Média 8
4.3 Aplicação Empírica 8

5 Estudo de Caso: Regressão Linear Aplicada à Pandemia de COVID-19 **9**
5.1 Dados Experimentais e Coleta 9
5.2 Ajuste do Modelo e Interpretação 9
5.3 Análise Crítica 9

1 Tópico 1: Introdução à distribuição Gaussiana

Nesta seção, iremos relatar sobre o conteúdo visto em aula dos dias 3 e 5 de março, referentes a introdução a distribuição Gaussiana, uma distribuição extremamente importante que descreve o comportamento de diversos fenômenos no mundo.

1.1 Lançamento de dados e funções geradoras

Antes de ver a distribuição propriamente vista, podemos observar em amostras menores um comportamento similar, como no exemplo dado em aula sobre a soma do valor do lançamento de 2 dados. Note que ao lançar 2 dados comuns de 6 lados, nós podemos obter como valor minímo 2 (ambos os dados nos dão 1) e máximo de 12 (ambos os dados nos dão 6), que implica que o valor médio a ser obtido da soma dos dados é $\frac{2+12}{2} = 7$. Repare que estes são os únicos valores com somente 1 forma de serem obtidos, enquanto que valores intermediários podem ser obtidos de múltiplas maneiras. Ex: o valor 7 pode ser obtido a partir dos lançamentos $1+6$, $2+5$, $3+4$, $4+3$, $5+2$, $6+1 \longrightarrow$ o resultado 7 é observado 6 vezes.

1.1.1 Funções Geradoras

Podemos facilmente descrever o lançamento dos dados fazendo uso de funções geradoras, onde utilizaremos uma soma de potências para marcar posições (ou nesse caso, cada potência indica qual foi o valor do dado observado) e seu coeficiente indica o número de vezes que esse resultado foi observado no experimento. Descrevemos o lançamento de um dado como simplesmente sendo

$$x + x^2 + x^3 + x^4 + x^5 + x^6$$

onde no caso de um dado apenas, nós observamos cada resultado apenas. Para simular o lançamento de n dados, basta multiplicar a função por si mesma n vezes:

$$(x + x^2 + x^3 + x^4 + x^5 + x^6)^n = x^n \frac{(1-x^6)^n}{1-x}$$

para $|x| < 1$. No caso de

$$n = 2 \Longrightarrow (x + x^2 + x^3 + x^4 + x^5 + x^6)^2$$

que pode ser expandido no polinômio $x^2 + 2x^3 + 3x^4 + 4x^5 + 5x^6 + 6x^7 + 5x^8 + 4x^9 + 3x^{10} + 2x^{11} + x^{12}$.

1.1.2 Probabilidade de um resultado com funções geradoras

Um dos casos analisados em sala foi: Feitos os lançamentos de 5 dados, qual a probabilidade de se observar o valor 20? Para isto, basta pegar nosso caso favorável e dividir pelo total de casos, ou seja, analisaremos o coeficiente de x^{20} dentro da função $(x+x^2+x^3+x^4+x^5+x^6)^5 = x^5\frac{(1-x^6)^5}{1-x}$. Expandindo o resultado da função no Mathematica, obtemos que o coeficiente de x^{20} é 651, portanto, a probabilidade de se observar o resultado 20 é de $\frac{651}{6^5} = \frac{651}{7776} = \frac{217}{2592} \approx 0,0837$.

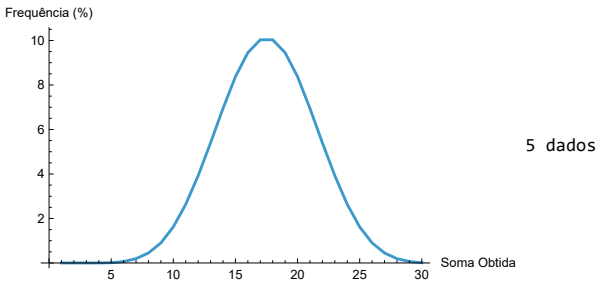


Figura 1: Gráfico da distribuição de probabilidade das somas resultantes do lançamento simultâneo de cinco dados cúbicos honestos.

1.1.3 Resultados com outros tipos de dados

Existem, além dos cubos (6 faces), outras formas de poliedros com todas as faces idênticas, mais conhecidas como Sólidos de Platão. Eles são o tetraedro (4 lados), o octaedro (8 lados), o dodecaedro (12 lados) e o icosaedro (20 lados). Com isso analisamos também a soma das faces enumeradas

usando funções geradoras e expandindo polinômios, segue para o caso de dois dados de mesmo piliedro:

- Tetraedro

$$x^8 + 2x^7 + 3x^6 + 4x^5 + 3x^4 + 2x^3 + x^2$$

- Octaedro

$$x^{16} + 2x^{15} + 3x^{14} + 4x^{13} + 5x^{12} + 6x^{11} + 7x^{10} + 8x^9 + 7x^8 + 6x^7 + 5x^6 + 4x^5 + 3x^4 + 2x^3 + x^2$$

- Dodecaedro

$$x^{24} + 2x^{23} + 3x^{22} + 4x^{21} + 5x^{20} + 6x^{19} + 7x^{18} + 8x^{17} + 9x^{16} + 10x^{15} + 11x^{14} + 12x^{13} + 11x^{12} + 10x^{11} + 9x^{10} + 8x^9 + 7x^8 + 6x^7 + 5x^6 + 4x^5 + 3x^4 + 2x^3 + x^2$$

- Icosaedro

$$x^{40} + 2x^{39} + 3x^{38} + 4x^{37} + 5x^{36} + 6x^{35} + 7x^{34} + 8x^{33} + 9x^{32} + 10x^{31} + 11x^{30} + 12x^{29} + 13x^{28} + 14x^{27} + 15x^{26} + 16x^{25} + 17x^{24} + 18x^{23} + 19x^{22} + 20x^{21} + 19x^{20} + 18x^{19} + 17x^{18} + 16x^{17} + 15x^{16} + 14x^{15} + 13x^{14} + 12x^{13} + 11x^{12} + 10x^{11} + 9x^{10} + 8x^9 + 7x^8 + 6x^7 + 5x^6 + 4x^5 + 3x^4 + 2x^3 + x^2$$

1.2 A distribuição Gaussiana

Conforme o número n de lançamentos aumenta, o gráfico dos resultados converge cada vez mais para o que chamamos de Curva Normal ou Distribuição Gaussiana. A Gaussiana é definida pela função $g(x, \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$, onde μ é a média populacional da curva, isto é, seu ponto central onde se encontra a maior densidade dos dados; e σ é o desvio padrão da curva, que nos dá a informação da amplitude dos nossos dados, ou seja, o quanto eles variam em relação a média μ. O desvio padrão pode ser obtido pela fórmula

$$\sigma = \sqrt{\sum_{i=1}^{n} \frac{(x_i - \mu)^2}{n-1}}$$

Já a média μ pode ser obtida pela média ponderada dos valores observados e o seu número de observações. O motivo da Gaussiana ser definida dessa forma é devido ao fato que a função $f(x) = e^{-x^2}$ tem uma integral de resultado $\int e^{-x^2} dx = \sqrt{\pi}$. A integral, logicamente, não possui uma solução analítica uma vez que a função $f(x)$ não possui uma primitiva. Podemos obter o resultado acima calculando o valor ao quadrado da integral no formato

$$\int_{-\infty}^{\infty} e^{-x^2} dx \int_{-\infty}^{\infty} e^{-y^2} dy =$$

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-x^2} e^{-y^2} dx dy =$$

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-(x^2+y^2)} dx dy =$$

$$\int_{0}^{2\pi} \int_{-\infty}^{\infty} r e^{-r^2} dr d\theta = \pi$$

onde esta última possui solução analítica e tem como resultado π, como este é o resultado do quadrado da nossa raiz inícial, então nossa integral inicial tem como valor $\sqrt{(}\pi)$. Para a integral gaussiana, podemos converte-la na integral acima fazendo a substituição de variável

$$y = \frac{x-\mu}{\sigma} \iff dy = \frac{dx}{\sigma}$$

Com essa substituição podemos observar que o motivo do fator $\frac{1}{\sqrt{2\pi}\sigma}$ é para normalizar a integral em função da media μ e do desvio padrão σ, fazendo com que o resultado da integral nos dois extremos $-\infty$ e ∞ seja 1, obedecendo assim o segundo axioma de Kolmogorov, em que $P(\Omega) = 1$, onde Ω é o nosso espaço amostral, nesse caso nossa curva Gaussiana. Mostraremos

abaixo como a distribuição da soma normalizada se aproxima a uma Gaussiana conforme o número de dados aumenta, para cada formato de dado.

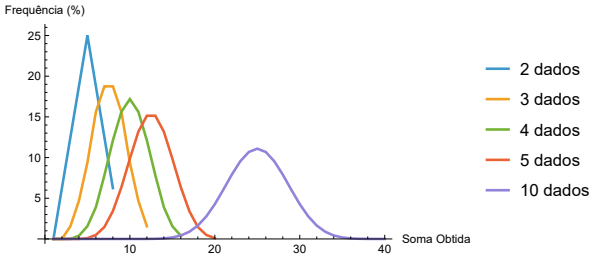


Figura 2: Distribuição de frequências para o lançamento de n dados de 4 lados.

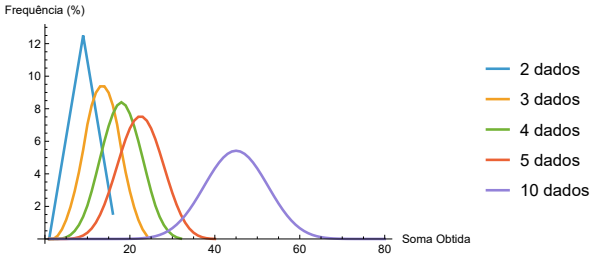


Figura 3: Distribuição de frequências para o lançamento de n dados de 8 lados.

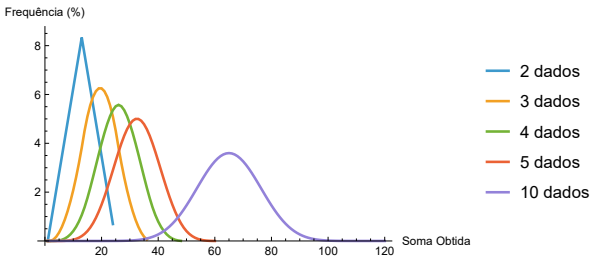


Figura 4: Distribuição de frequências para o lançamento de n dados de 12 lados.

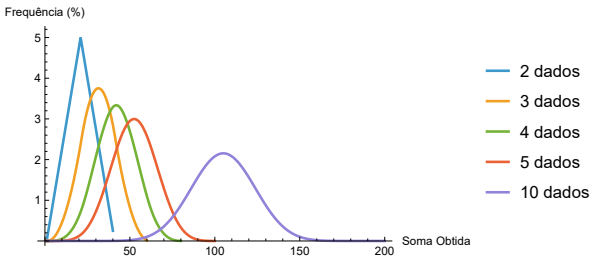


Figura 5: Distribuição de frequências para o lançamento de n dados de 20 lados.

2 Tópico 2: Relative Risk, Odds Ratio e Hazard Ratio

Neste tópico, faremos uma breve definição acerca das taxas RR, OR e HR e seus significados.

2.1 Relative Risk (RR)

Relative Risk (RR) é uma taxa obtida a partir da fórmula das probabilidades $P(A|E_x)$ e $P(A|nE_x)$, onde A é o evento a ser observado e E_x uma condição ou procedimento aplicado no grupo amostral em que queremos observar A (onde nE_x seria a ausência dessa condição). A partir delas, obtemos

$$RR = \frac{P(A|E_x)}{P(A|nE_x)}$$

, onde concluímos que: $RR > 1 \implies$ O evento A ocorre mais no grupo que sofreu exposição; $RR < 1 \implies$ O evento A ocorre mais no grupo não sofreu exposição; $RR = 1 \implies$ O evento A ocorre com mesma frequência em ambos os grupos, ou seja, a exposição não surte efeito nenhum. Essa razão é extremamente útil no contexto de vacinas, onde podemos analisar casos graves de uma doença entre grupos de indíviduos vacinados e não vacinados, e, com isto, analisar a proporção de casos graves entre os dois grupos para analisar a eficácia da vacina.

2.2 Odds Ratio (OR)

Odds Ratio (OR) é similar a RR, porém ela é calculada por meio da razão das odds do evento A entre o grupo exposto sobre o grupo não-exposto. A OR tem uma tendência de hiperestimar o efeito em relação ao RR, então é interessante levar isso em consideração caso queira criar uma margem de segurança para os casos que não se observa

A. OR é dado por

$$OR = \frac{\frac{P(A|E_x)}{1-P(A|E_x)}}{\frac{P(A|nE_x)}{1-P(A|nE_x)}}.$$

O OR tende a aproximar o RR quando o evento A é raro.

2.3 Hazard Ratio (HR)

O Hazard Ratio (HR) é uma taxa com variação ao longo do tempo, ou seja, suponhamos que no nosso experimento com OR no contexto da vacina nos retorna valores diferentes conforme o tempo passa. Nesse contexto, o HR seria a taxa que nos da média dos valores de OR ao longo de diferentes momentos. Sua fórmula geral pode ser escrita como

$$HR = \frac{h_{E_x}(t)}{h_{nE_x}(t)},$$

onde $h(t)$ é a função que descreve a proporção observada por grupo ao longo do tempo t. No contexto discreto utilizando OR, HR seria simplesmente a média aritmética de OR ao longo dos n tempos observados.

3 Tópico 3: Introdução a Regressão Linear

A análise de regressão linear estabelece uma base teórica para modelar o comportamento de uma variável resposta Y a partir de uma variável independente x. Distanciando-se de determinismos estritos, a natureza do fenômeno mensurado inclui perturbações inobserváveis. O modelo adota uma componente estocástica para capturar essa incerteza. Neste relatório, exploramos a formulação formal do modelo, a inferência clássica e as medidas de adequação do ajuste.

3.1 O Modelo Estocástico e Hipóteses

O modelo de regressão linear simples postula que a variável resposta Y_i se relaciona com o regressor x_i através da equação:

$$Y_i = \beta x_i + \alpha + \varepsilon_i, \qquad i = 1, \ldots, N, \quad (1)$$

onde β (inclinação) e α (intercepto) são os parâmetros populacionais desconhecidos e ε_i é o erro aleatório da i-ésima observação.

Assumimos que os regressores x_i são fixos (matriz de projeto não-estocástica) e que os erros satisfazem as seguintes hipóteses:

1. **Média zero condicional:** $\mathbb{E}[\varepsilon_i \mid X] = 0$.

2. **Homocedasticidade:** $\mathrm{Var}(\varepsilon_i \mid X) = \sigma^2$, constante para todo i.

3. **Erros não correlacionados:** $\mathrm{Cov}(\varepsilon_i, \varepsilon_j \mid X) = 0$ para $i \neq j$.

Sob as hipóteses estruturais acima, o Teorema de Gauss-Markov garante que os estimadores de mínimos quadrados são os Melhores Estimadores Lineares Não-Viesados (BLUE). Para a construção de testes de hipótese e intervalos exatos em amostras finitas, supomos adicionalmente:

4. **Normalidade dos Erros:** $\varepsilon_i \mid X \sim \mathcal{N}(0, \sigma^2)$, o que implica a independência estatística plena dos erros.

3.2 Definições Prévias

Antes de formularmos a solução, definimos as quantidades amostrais de espalhamento. Adotaremos a notação $\langle \cdot \rangle$ para denotar estritamente o estimador da média amostral, onde $\langle x \rangle = \frac{1}{N} \sum_{i=1}^{N} x_i$. Seja N o tamanho da amostra:

$$S_{xx} = \sum_{i=1}^{N}(x_i - \langle x\rangle)^2 = N(\langle x^2\rangle - \langle x\rangle^2), \tag{2}$$

$$S_{yy} = \sum_{i=1}^{N}(y_i - \langle y\rangle)^2 = N(\langle y^2\rangle - \langle y\rangle^2), \tag{3}$$

$$S_{xy} = \sum_{i=1}^{N}(x_i - \langle x\rangle)(y_i - \langle y\rangle) = N(\langle xy\rangle - \langle x\rangle\langle y\rangle). \tag{4}$$

3.3 Estimadores de Mínimos Quadrados

Desejamos estimar β e α através dos estimadores amostrais a (inclinação) e b (intercepto), ajustando o modelo $\hat{y}_i = ax_i + b$. Para representarmos o sistema na forma matricial, definimos a matriz de projeto $X \in \mathbb{R}^{N\times 2}$, o vetor resposta $Y \in \mathbb{R}^N$ e o vetor de estimadores $\hat{\theta} \in \mathbb{R}^2$:

$$X = \begin{pmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{pmatrix}, \quad Y = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix}, \quad \hat{\theta} = \begin{pmatrix} a \\ b \end{pmatrix}. \tag{5}$$

A minimização da norma dos resíduos observáveis leva às equações normais $X^TX\hat{\theta} = X^TY$. Assumindo $S_{xx} > 0$, a matriz de informação de Fisher empírica é:

$$X^TX = N\begin{pmatrix} \langle x^2\rangle & \langle x\rangle \\ \langle x\rangle & 1 \end{pmatrix}. \tag{6}$$

O determinante associado é $\Delta = N^2(\langle x^2\rangle - \langle x\rangle^2) = NS_{xx}$. A inversão resulta na matriz associada às variâncias dos estimadores:

$$(X^TX)^{-1} = \frac{1}{S_{xx}}\begin{pmatrix} 1 & -\langle x\rangle \\ -\langle x\rangle & \langle x^2\rangle \end{pmatrix}. \tag{7}$$

Realizando a pré-multiplicação pelo vetor $X^TY = N\begin{pmatrix}\langle xy\rangle \\ \langle y\rangle\end{pmatrix}$, obtemos o vetor $\hat{\theta}$:

$$\hat{\theta} = \frac{N}{S_{xx}}\begin{pmatrix} \langle xy\rangle - \langle x\rangle\langle y\rangle \\ -\langle x\rangle\langle xy\rangle + \langle x^2\rangle\langle y\rangle \end{pmatrix}. \tag{8}$$

Isolando os componentes, a inclinação a emerge diretamente da primeira linha:

$$a = \frac{N(\langle xy\rangle - \langle x\rangle\langle y\rangle)}{S_{xx}} = \frac{S_{xy}}{S_{xx}}. \tag{9}$$

Para o intercepto b, a partir da segunda linha e rearranjando os termos centrais, deduz-se:

$$b = \frac{N(\langle x^2\rangle\langle y\rangle - \langle x\rangle\langle xy\rangle)}{S_{xx}} = \langle y\rangle - \left[\frac{\langle xy\rangle - \langle x\rangle\langle y\rangle}{\langle x^2\rangle - \langle x\rangle^2}\right]\langle x\rangle = \langle y\rangle - a\langle x\rangle. \tag{10}$$

3.4 Exemplo Dado em Sala de Aula

Para consolidar o formalismo matemático discutido anteriormente, apresenta-se um exemplo prático de regressão linear simples, fundamentado em dados coletados em sala de aula. O objetivo é analisar a correlação entre o tempo dedicado ao estudo (x, em horas) e o desempenho acadêmico final (y, nota de 0 a 10).

3.4.1 Conjunto de Dados e Amostragem

A amostra consiste em pares ordenados (x_i, y_i), onde x representa a variável independente (horas estudadas) e y a variável dependente (nota obtida). Os dados observados na amostra são apresentados na Tabela 1.

Tabela 1: Pares observados na amostra (Horas estudadas vs. Notas)

x_i	y_i	x_i	y_i	x_i	y_i
6.7	8.0	8.0	10.0	7.0	8.0
6.5	7.0	6.0	8.0	6.5	6.0
7.0	7.0	7.5	10.0	8.5	9.0
5.5	5.0	4.5	4.0		

3.4.2 Ajuste do Modelo e Análise de Convergência

Utilizando o método dos mínimos quadrados, implementado via *Mathematica*, buscamos uma função linear do tipo $y = \beta_0 + \beta_1 x$ que minimize a soma dos quadrados dos resíduos. O modelo resultante para a estimativa da nota $\hat{y}$ é dado por:

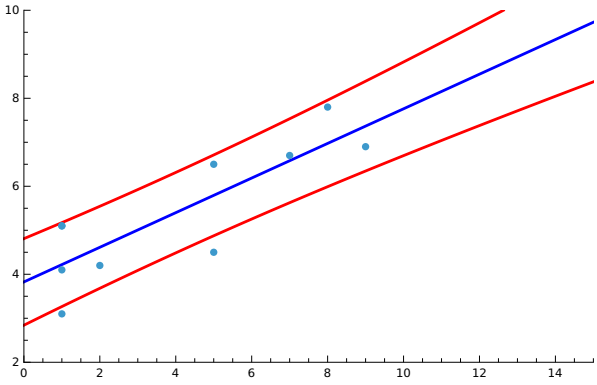
$$\hat{y} = 1,48 \cdot x - 2,49 \tag{11}$$

A análise estatística indica uma forte correlação positiva entre as variáveis. O coeficiente de determinação (R^2) obtido foi de aproximadamente $0,756$, sugerindo que $75,6\%$ da variabilidade das notas pode ser explicada pelo tempo de estudo dedicado.

3.4.3 Interpretação Física e Gráfica

O coeficiente angular ($\beta_1 \approx 1,48$) representa a taxa de ganho de desempenho por hora adicional de estudo. Sob a ótica do formalismo aqui discutido, a relação linear atua como um previsor estatístico robusto dentro do intervalo amostral.

Graficamente, observa-se que os pontos experimentais orbitam a reta de regressão com desvios mínimos, validando a aplicação do modelo para este conjunto de dados específico. Essa análise reforça a importância da parametrização correta em sistemas onde variáveis independentes ditam a evolução do resultado final.



4 Análise de Variância e Resíduos

A Soma dos Quadrados dos Resíduos (SQR) é expressa por:

$$\text{SQR} = \sum_{i=1}^{N} (y_i - a x_i - b)^2 = S_{yy} - a S_{xy}. \tag{12}$$

Classificamos $\hat{\sigma}^2 = \text{SQR}/(N-2)$ como o estimador não-viesado da variância do erro. A propriedade de não-viés, $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$, decorre da esperança da forma quadrática dos resíduos matriciais $\mathbb{E}[Y^T M Y] = \sigma^2 \,\text{tr}(M)$, onde $M = I - X(X^T X)^{-1} X^T$ é uma matriz idempotente com traço $N-2$. O desvio padrão residual é:

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{S_{yy} - a S_{xy}}{N-2}}. \tag{13}$$

4.1 Qualidade de Ajuste (R^2)

O coeficiente de determinação avalia a proporção da variabilidade total explicada pelo modelo. A decomposição $S_{yy} = \text{SQReg} + \text{SQR}$ permite definir:

$$R^2 = 1 - \frac{\text{SQR}}{S_{yy}} = 1 - \frac{S_{yy} - a S_{xy}}{S_{yy}} = \frac{a S_{xy}}{S_{yy}}. \tag{14}$$

Ressalta-se que a decomposição exata das somas de quadrados só é ortogonal graças à presença do parâmetro de intercepto no modelo, o qual impõe a restrição $\sum e_i = 0$. Em amostras pequenas, adota-se o R^2 ajustado:

$$R^2_{\text{adj}} = 1 - \frac{N-1}{N-2}(1 - R^2). \tag{15}$$

4.2 Inferência Estatística

4.2.1 Erros Padrão e Teste de Hipótese

Os erros padrão (EP) indicam a imprecisão estocástica na estimação dos coeficientes:

$$\text{EP}(a) = \frac{\hat{\sigma}}{\sqrt{S_{xx}}}, \quad \text{EP}(b) = \hat{\sigma}\sqrt{\frac{1}{N} + \frac{\langle x \rangle^2}{S_{xx}}}. \tag{16}$$

Realizamos um teste t para a hipótese nula $H_0 : \beta = 0$ (inclinação nula). A estatística de teste é:

$$T = \frac{a}{\mathrm{EP}(a)} \sim t_{N-2} \quad (\text{sob } H_0). \tag{17}$$

Rejeitamos H_0 se $|T| > t_{1-\gamma/2,N-2}$, onde γ é o nível de significância adotado.

4.2.2 Intervalos de Confiança para Parâmetros

Assumindo a normalidade, construímos intervalos com nível de confiança de $100(1-\gamma)\%$ para β e α, respectivamente:

$$a \pm t_{1-\gamma/2,N-2} \cdot \mathrm{EP}(a), \quad b \pm t_{1-\gamma/2,N-2} \cdot \mathrm{EP}(b). \tag{18}$$

4.2.3 Intervalos de Previsão e Resposta Média

Dado um ponto observacional x_p, distinguem-se dois intervalos de interesse:

$$\text{Confiança } (\mathbb{E}[Y \mid x_p]): \tag{19}$$

$$\hat{y}p \pm tc \cdot \hat{\sigma}\sqrt{\frac{1}{N} + \frac{(x_p - \langle x \rangle)^2}{S_{xx}}}, \tag{20}$$

$$\text{Predição } (Y_{\text{novo}}): \tag{21}$$

$$\hat{y}p \pm tc \cdot \hat{\sigma}\sqrt{1 + \frac{1}{N} + \frac{(x_p - \langle x \rangle)^2}{S_{xx}}}, \tag{22}$$

onde $t_c = t_{1-\gamma/2,N-2}$. O termo extra $+1$ sob o radical contabiliza a variância estocástica da nova realização $\varepsilon_{\text{novo}}$.

4.3 Aplicação Empírica

Como base ilustrativa do processo, considere as medições de $N = 11$ dados empíricos dispostos a seguir:

Tabela 2: Pares observados na amostra

x_i	y_i	x_i	y_i	x_i	y_i
6.7	8	8.0	10	7.0	8
6.5	7	6.0	8	6.5	6
7.0	7	7.5	10	8.5	9
5.5	5	4.5	4		

A partir destes dados, extraímos as somas brutas: $\sum x_i = 73.7$, $\sum y_i = 82$, $\sum x_i^2 = 506.39$, $\sum y_i^2 = 648$ e $\sum x_i y_i = 568.1$. Temos a média exata $\langle x \rangle = 6.7$ e a representação fracionária exata da média $\langle y \rangle = 82/11$.

Calculamos os espalhamentos utilizando frações para evitar a propagação de erros de arredondamento:

$$S_{xx} = 506.39 - 11(6.7^2) = 12.6,$$
$$S_{yy} = 648 - 11\left(\frac{82}{11}\right)^2 = \frac{404}{11} \approx 36.727,$$
$$S_{xy} = 568.1 - 11(6.7)\left(\frac{82}{11}\right) = 18.7.$$

Obtemos a inclinação $a = 18.7/12.6 \approx 1.484$ e o intercepto $b = (82/11) - (1.484)(6.7) \approx -2.489$. O estimador da variância residual provém da SQR exata:

$$\mathrm{SQR} = S_{yy} - aS_{xy} = \frac{404}{11} - \frac{18.7^2}{12.6} \approx 8.9741.$$

Logo, o desvio padrão residual é $\hat{\sigma} = \sqrt{8.9741/9} \approx 0.9986$. O coeficiente de determinação é calculado como $R^2 = 18.7^2/(12.6 \times (404/11)) \approx 0.7556$. O modelo explica cerca de 75.6% da variabilidade.

Aplicamos o teste de hipótese para a inclinação. O erro padrão é $\mathrm{EP}(a) = \hat{\sigma}/\sqrt{S_{xx}} \approx 0.9986/\sqrt{12.6} \approx 0.2813$. A estatística correspondente é $T = 1.4841/0.2813 \approx 5.275$. Comparando com o valor crítico da distribuição t ($t_{0.975,9} \approx 2.262$), constatamos que $5.275 \gg 2.262$. Rejeitamos a hipótese nula de que $\beta = 0$, provendo evidência de uma associação linear estatisticamente significativa. Para uma validação estrutural completa, a análise de resíduos gráfica desta amostra confirmou a ausência de padrões não lineares aparentes e a preservação razoável da homocedasticidade.

5 Estudo de Caso: Regressão Linear Aplicada à Pandemia de COVID-19

Nesta seção, expande-se a aplicação prática do formalismo de regressão linear para o contexto epidemiológico, analisando a fase inicial de disseminação da COVID-19 no Brasil. O objetivo é modelar o crescimento do número de casos acumulados (N) em função do tempo (t), demonstrando a eficácia da linearização de modelos exponenciais.

5.1 Dados Experimentais e Coleta

Os dados brutos coletados referem-se ao número total de casos confirmados em dias específicos de março de 2020. Para possibilitar a análise via regressão linear, aplica-se o logaritmo natural (ln) sobre o número de casos, transformando o crescimento exponencial em uma relação linear: $\ln(N) = \ln(N_0) + k \cdot t$.

Tabela 3: Dados de casos acumulados de COVID-19 no Brasil e sua linearização.

Dia (t)	Casos (N)	ln(N)
1	151	5,02
5	621	6,43
10	2.433	7,80
15	6.836	8,83
20	13.715	9,53

5.2 Ajuste do Modelo e Interpretação

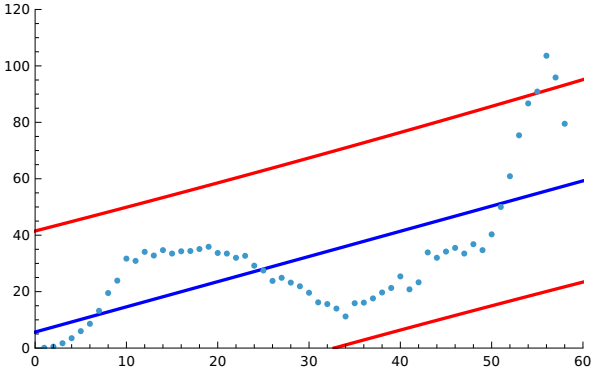
A partir do ajuste linear realizado sobre os dados da Tabela 3, obteve-se a seguinte equação da reta para o logaritmo do número de casos:

$$y = 0,24 \cdot x + 5,09 \tag{23}$$

Onde $y = \ln(N)$ e $x = t$. O coeficiente angular ($k \approx 0,24$) representa a taxa de crescimento diário. Retornando à forma original, o modelo exponencial resultante é dado por:

$$N(t) = 162,39 \cdot e^{0,24 \cdot t} \tag{24}$$

5.3 Análise Crítica



A representação gráfica da linearização revela uma correlação extremamente alta, validando o uso de modelos lineares transformados para descrever fenômenos de crescimento acelerado. Esta análise, similar ao estudo dos potenciais quânticos e distribuições gaussianas discutidos nas seções 2.3 e 2.4, demonstra que a parametrização adequada é a chave para a interpretação de sistemas complexos.